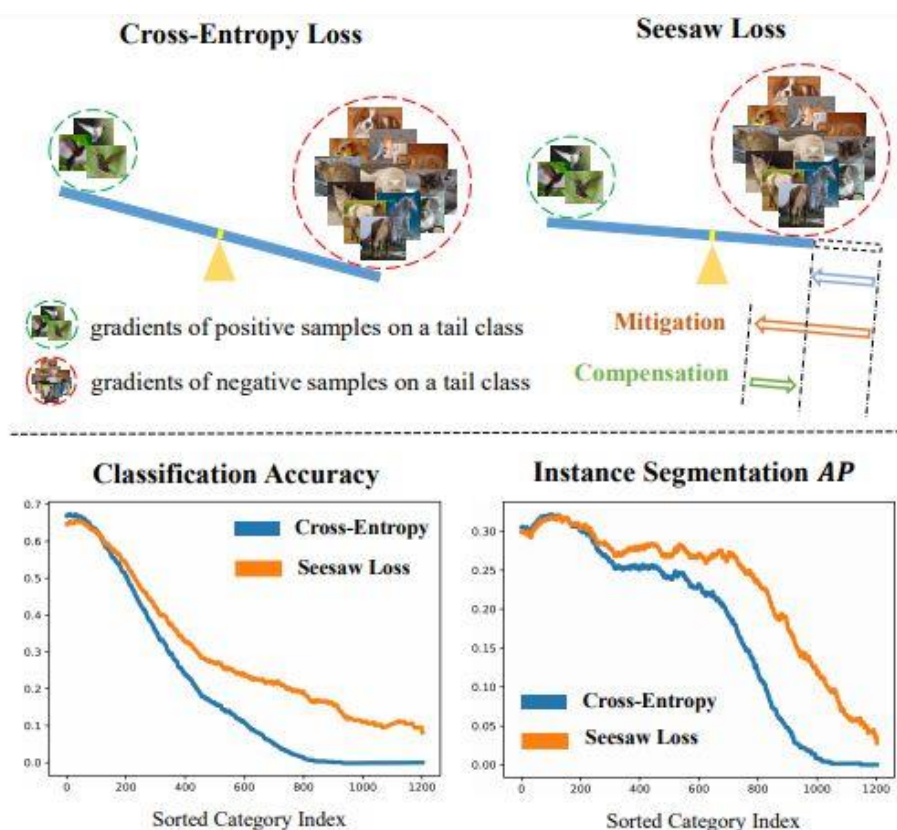


长尾目标检测

1. Seesaw Loss for Long-Tailed Instance Segmentation

论文: <https://arxiv.org/abs/2008.10032>

代码: <https://github.com/open-mmlab/mmdetection>



文章指出了尾部类别上的正负样本梯度的不平衡是影响长尾检测性能的关键因素之一，因此提出了 Seesaw Loss 来针对性地调整施加在任意一个类别上的负样本梯度。给定一个尾部类别和一个相对更加高频的类别，高频类施加在尾部类上的负样本梯度将根据两个类别在训练过程中累计样本数的比值进行减弱。同时为了避免因负样本梯度减弱而增加的误分类的风险，Seesaw Loss 根据每个样本是否被误分类动态地补充负样本梯度。Seesaw Loss 有效地平衡了不同类别的正负样本梯度，提高了尾部类别的分类准确率，在长尾目标检测/实例分割数据集 LVIS v1.0 带来了上显著的性能提升。

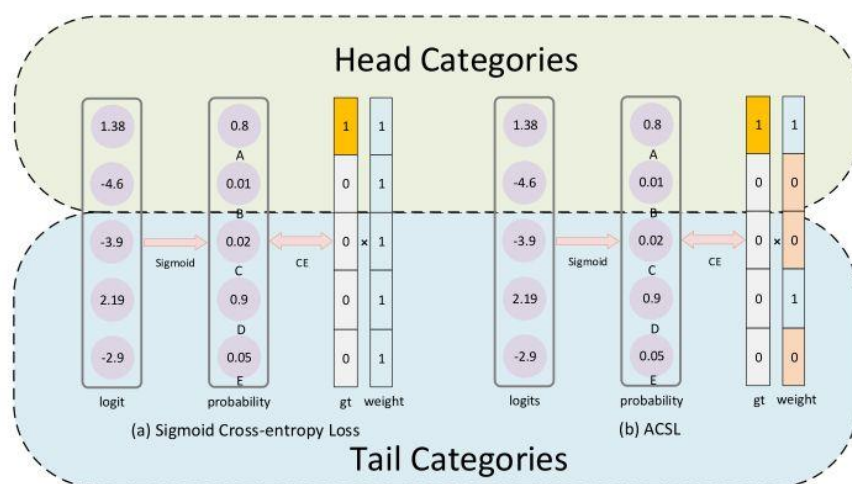
2. Adaptive Class Suppression Loss for Long-Tail Object Detection

论文: <https://arxiv.org/abs/2104.00885>

代码: <https://github.com/CASIA-IVA-Lab/ACSL>

提出 Adaptive Class Suppression Loss (ACSL), 有效地防止相邻类别的训练不一致, 提高稀有类别的判别能力。在长尾数据集 LVIS 和 Open Images 上的大量实验表明, ACSL 与 ResNet50-FPN 相比, 分别取得了 5.18% 和 5.2% 的提升, 实现了新的 SOTA。

比较满意的损失函数应满足: ①应该保护尾部分类器不被压倒性的头部样本过度抑制。同时, 容易混淆的类别的负梯度应该被保留用于辨别学习。②最好不依赖于标签分布先验, 以便它可以应用于不同的数据集, 而无需重新计算新的类别分布统计。



文中给出了一个容易理解的例子: 对于 sigmoid 交叉熵损失 (图(a)), 它没有考虑不平衡的类分布, 直接对其他所有类别产生负梯度, 从而导致尾部类别连续接收大量抑制信息, 严重降低了尾部分类器的区分能力。对于 ACSL, 如图(b)所示, 这意味着类别 “A” 在语义上类似于类别 “D”, 有必要对类别 “D” 产生否定抑制, 而不是对具有低置信度的剩余尾部类别产生否定抑制。

3. Equalization Loss v2: A New Gradient Balance Approach for Long-tailed Object Detection

论文: <https://arxiv.org/abs/2012.08548>

代码: <https://github.com/tztztztztz/eqlv2>

指出提高长尾目标检测性能的关键是保持阳性和阴性之间的梯度平衡。并提出 EQL 的改良版本 EQL v2, 在训练阶段动态地平衡阳性与阴性之间的梯度比例。梯度引导的平衡再加权的基本思想是, 根据每个分类器的正梯度与负梯度的累积比率, 独立地增加正梯度的权重和减少负梯度的权重。

在 LVIS 基准测试上实验表明, EQL v2 在整体上比原 EQL 高出约 4 个点, 在罕见类别上有 14-18 个点的改进。更重要的是, 它还超过了解耦训练方法。在没有进一步调整开放图像数据集的情况下, EQL v2 将 EQL AP 值提高了 7.3 个点, 显示了它强大的泛化能力。

